

Cours n°8

Gestion des documents

Sommaire

1. Gestion des documents textuels

1. Interfaces de modélisation
2. Visualisation et Edition

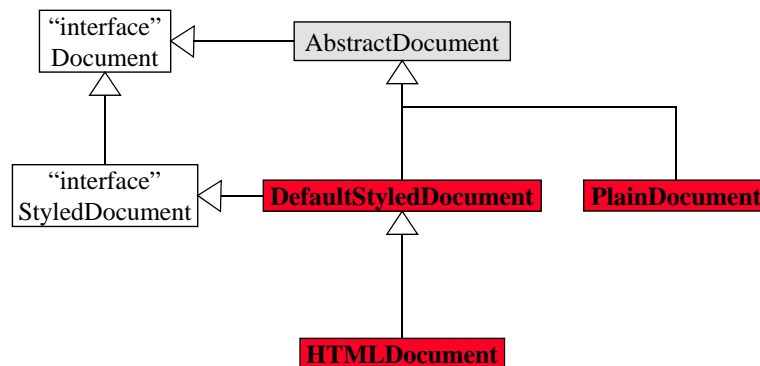
2. Analyse de documents XML

1. Simple API for XML (SAX)
2. Document Object Mode (DOM)

1. GESTION DES DOCUMENTS TEXTUELS

Modélisation

Trois classes concrètes



1.1 INTERFACES DE MODELISATION

Document

Spécification du contrat que toutes les types de document doivent implémenter

Texte du document
String **getText** (int début, int taille)
void **getText** (int début, int taille, Segment cc)

Nombre de caractères du document
int **getLength** ()

Ajout d'un texte cc à l'indice i du document
void **insertString**(int i, String cc, AttributeSet a)

Suppression d'une partie du texte à partir de l'indice i du document
void **remove**(int i, int taille)

Positionnement d'une marque au ième caractère
Position **createPosition** (int i)

Ajout d'un écouteur d'événement modification de document
void **addDocumentListener** (DocumentListener dl)

Interface Position

Indice correspondant à la position d'une marque
int **getOffset**()

StyledDocument - Typographie

Création, Gestion et Utilisation de styles de typographie

Création des styles

Applications des méthodes de la classe StyleConstants

```
static void setBackground(Style s, Color c)    // couleur de fond
static void setForeground(Style s, Color c)    // couleur du caractère

static void setFontFamily(Style s, String cc)  // police
static void setFontSize(Style s, int corps)    // corps

static void setBold(Style s, boolean b)        // gras
static void setItalic(Style s, boolean b)      // italique
static void setSubscript(Style s, float x)     // indice
static void setSuperscript(Style s, float x)   // exposant

static void setAlignment(Style s, int align)   // alignement (gauche, droit, ..)
static void setFirstLineIndent(Style s, float x) // Indentation
static void setLeftIndent(Style s, float x)
static void setRightIndent(Style s, float x)

static void setSpaceAbove(Style s, float x)
static void setSpaceBelow(Style s, float x)
static void setLineSpacing(Style s, float x)  // taille des lignes
```

StyledDocument - Styles

Gestion des styles

Ajout d'un style s dans la hiérarchie h des styles précédemment définis
Style `addStyle(Style s, Style h)`

Recherche du style s
Style `getStyle(String cc)`

Suppression du style s
void `removeStyle(String cc)`

Recherche du style du paragraphe contenant le caractère d'indice i
Style `getLogicalStyle(int i)`

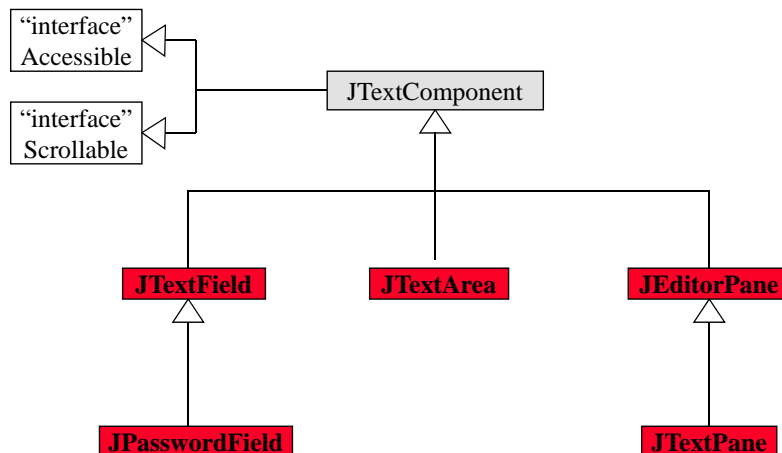
Utilisation des styles

Application ou ajout du style s à une partie du texte
void `setCharacterAttributes(int i, int taille, Style s, boolean app)`

Application du style s au paragraphe contenant le caractère d'indice i
void `setLogicalStyle(int pos, Style s)`

Introduction

Cinq classes concrètes



Classe JTextComponent

Classe abstraite, ancêtre de tous les classes de visualisation de texte

Définition de plus de 100 méthodes

Lien avec un document

void `setDocument(Document doc)`

Gestion du sélecteur (caret)

void `setCaretPosition(int i)` **int** `getCaretPosition()`

Sélection d'une zone de texte

void `select(int début, int fin)` **void** `selectAll()`

Lecture et écriture d'un fichier texte

void `write(Writer out)` **void** `read(Reader in, Object desc)`

Méthodes interactives d'édition (possibilité de redéfinition)

void `copy()` **void** `cut()` **void** `paste()`

Ecouleurs

void `addCaretListener(CaretListener listener)`

Classe JTextArea

Composant de visualisation de documents textuels simples

Compatibilité avec les documents de type PlainDocument,
Vue d'une partie du document (implémentation de l'interface Scrollable),
Contrôle des coupures de fin de ligne

Constructeurs

Constructeur vide

JTextArea()

Construction à partir du document doc avec l lignes, c colonnes, et le titre t

JTextArea(Document doc, String t, int l, int c)

JTextArea(Document doc)

JTextArea(String t, int l, int c)

JTextArea(String t)

JTextArea(int l, int c)

Gestion des fin de ligne et des tabulations

void setLineWrap(boolean wrap) void setWrapStyleWord(boolean word)

void setTabSize(int taille)

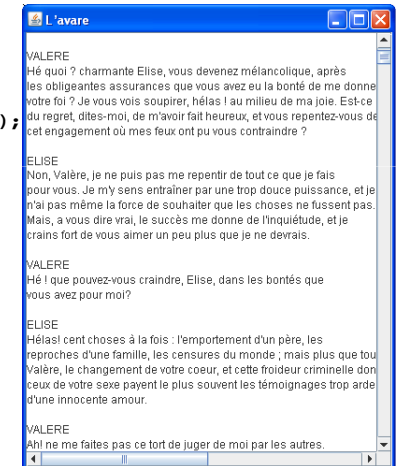
JTextArea – Programme

```
PlainDocument pdoc = new PlainDocument();
String NomFichier = "livres/avare.txt";
pdoc.putProperty("Titre", NomFichier);
```

```
JTextArea ta = new JTextArea(pdoc);
```

```
try {
    ta.read(new FileReader(NomFichier), null);
}
catch (IOException e) {}
```

```
JFrame fen = new JFrame("L'avare");
fen.setSize(400, 500);
Container jp = fen.getContentPane();
jp.add(ta);
jp.add(new JScrollPane(ta));
fen.setVisible(true);
```



Classe JEditorPane

Composant de visualisation de documents textuels enrichis

Lecture des formats texte pur, RTF et HTML,
Initialisation à partir d'une URL
Gestion des hyperliens

Constructeurs

Constructeur vide

JEditorPane()

Construction à partir de la chaîne cc de format f (txt, rft, html)

JEditorPane(String f, String cc)

Construction à partir de l'URL u

JEditorPane(URL u)

Construction à partir d'une chaîne de caractère correspondant à une URL

JEditorPane(String url)

Classe JTextPane

Composant de visualisation de documents textuels enrichies

Classe dérivée de JEditorPane,
Compatibilité avec les documents de type DefaultStyledDocument,
Attachement d'images et de composants à des parties du texte

Constructeurs

Constructeur vide

JTextPane()

Construction à partir du document doc

JTextPane(StyledDocument doc)

Liens avec les documents

void setDocument(Document doc)

void setStyledDocument(StyledDocument doc)

Classe JTextPane – Programme (1/2)

```
String NomFichier = "livres/avare.txt";
JTextPane tp = new JTextPane();

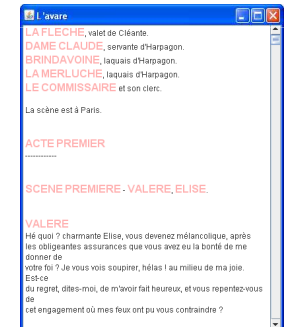
// lecture du document
try {
    tp.read(new FileReader(NomFichier), null); }
catch (IOException e) {}
String cc = null;
try {cc = dsdoc.getText(0, dsdoc.getLength()); }
catch (BadLocationException e) {}

// définition du style Personnage
StyledDocument dsdoc = tp.getStyledDocument();
dsdoc.putProperty("Titre", "L'avare");
Style s = dsdoc.addStyle("Personnage", null);
StyleConstants.setForeground(s, Color.PINK);
StyleConstants.setFontSize(s, 16);
StyleConstants.setBold(s, true);
```

Classe JTextPane – Programme (2/2)

```
//enrichissement du texte
BreakIterator bil = BreakIterator.getWordInstance();
bil.setText(cc);
int debut = bil.first();
for (int fin = bil.next(); fin != BreakIterator.DONE; debut = fin, fin = bil.next()) {
    if (cc.substring(debut, fin).matches("[A-Z]*"))
        dsdoc.setCharacterAttributes(debut, fin-debut, s, true);
}

//affichage
JFrame fen = new JFrame("L'avare");
fen.setSize(400, 500);
Container jp = fen.getContentPane();
jp.add(tp);
jp.add(new JScrollPane(tp));
fen.setVisible(true);
```



JAXP (Java API for XML processing)

Bibliothèque Java pour un traitement standardisé des données au format XML (java.sun.com/xml/jaxp)

Version 1.2.4

Disponible dans le kit de développement standard (depuis la version 1.4),

Packages javax.xml.parsers, javax.xml.transform

Indépendance aux outils d'analyse des données XML (ajouts par plug-in)

Support d'outils d'analyse : CRIMSON, SAX et DOM,

Support d'outils de transformation XSLT : XALAN.

Caractéristiques (1)

Nécessité d'une API Java de référence pour le parcours d'arborescence XML

1997 – projet YAXPAPI (Yet Another XML Parser API) en référence au programme YACC (Yet Another Compiler-Compiler) de Peter Murray-Rust

1998 – SAX Version 1.0 (Peter Murray-Rust, Tim Bray et David Megginson)

2000 – SAX Version 2.0 (www.saxproject.org)

Langages supportées

Pascal, C++ (Arabica), Perl (module), Python

Bibliothèque Microsoft (MS XML-3.0) accessible en VB, C et C++

Caractéristiques (2)

Ensemble de points d'entrées dans la procédure de parcours d'arbre (détecteur d'événements SAX)

Début du document (`startDocument`)

Fin du document (`endDocument`)

Balise de début (`startElement`)

Balise de fin (`endElement`)

Contenu (`characters`)

Erreur d'analyse (`error`)

Pas de création d'objets pendant le parcours

Peu de mémoire utilisée

Pas de mémorisation de l'arborescence

Implémentation en Java (1)

Librairie JAXP

+

Package `org.xml.java` (pas de support de Sun)

Classes (2), interfaces (11) et exceptions (2) pour la création et le lancement d'un analyseur SAX.

Package `org.xml.sax.helpers` (pas de support de Sun)

Classes (10) pour la gestion des points d'entrées (classe `DefaultHandler`) de l'analyseur SAX.

Implémentation en Java (2) – Classe `DefaultHandler`

Traitement des événements « début du document » et « fin du document »

`StartDocument()`

`EndDocument()`

Traitement de l'événement « début de balise »

`StartElement(String namespaceURI, String sName, String qName, Attributes attrs)`

`namespaceURI` : espace de noms

`sName` : nom de la balise (en cas d'espace de noms)

`qName` : nom de la balise (en cas d'absence d'espace de noms)

`attrs` : attribut de la balise

Implémentation en Java (3) – Classe `DefaultHandler`

Traitement de l'événement « fin de balise »

`EndElement(String namespaceURI, String sName, String qName)`

Traitement de l'événement « contenu entre deux balises »

`characters(char buf[], int offset, int len)`

`buf` : ensemble du texte analysé

`offset` : emplacement du 1er caractère après la balise de début

`len` : taille du contenu inter-balises

Construction d'un objet SAX

```
public class ParcoursArbreSax extends DefaultHandler {

    public ParcoursArbreSax(InputStream isXml) {
        super();
        // création d'une instance d'API SAX
        SAXParserFactory factory = SAXParserFactory.newInstance();
        factory.setValidating(true);

        //création d'un objet de parcours
        SAXParser saxParser = null;
        try {saxParser = factory.newSAXParser();}
        catch (SAXException e) {}
        catch (ParserConfigurationException e) {}

        // parcours utilisant le gestionnaire d'événement de this
        try {saxParser.parse(isXml, this);}
        catch (IOException e) {}
        catch (SAXException e) {}
    }
}
```

Lecture des balises et des attributs

```
public void startElement(String namespaceURI, String sName,
    String qName, Attributes attrs) throws SAXException {

    String eName = sName;
    if ("".equals(eName)) eName = qName;
    System.out.print("balise de début: ");
    System.out.print(eName);
    if (attrs != null) {
        // attributs
        for (int i = 0; i < attrs.getLength(); i++) {
            String aName = attrs.getLocalName(i);
            if ("".equals(aName)) aName = attrs.getQName(i);
            // nom
            System.out.print(" " + aName + "=\""");
            // valeur
            System.out.print(attrs.getValue(i)+"\"");
        }
    }
    System.out.println("");
}
```

Lecture des données

```
public void endElement(String namespaceURI, String sName,
    String qName) throws SAXException {
    String eName = sName;
    if ("".equals(eName)) eName = qName;
    System.out.println("balise de fin: "+eName);
}

public void characters(char buf[], int offset, int len)
    throws SAXException
{
    String s = new String(buf, offset, len);
    String st = s.trim();
    if (st.length() > 0)
        System.out.println(st);
}

public void startDocument() throws SAXException{
    System.out.println("début du document:");}
public void endDocument() throws SAXException{
    System.out.println("fin du document:");}
```

Extractions d'un fichier XML

```
import java.io.*;

/**
 * @author montacie
 */
public class testParcoursArbreSAX {

    public static void main(String[] args) {
        File fxml = new File("xml/article.xml");
        FileInputStream isxml = null;
        try {
            isxml = new FileInputStream(fxml);
        }
        catch (IOException e) {}

        ParcoursArbreSax ges = new ParcoursArbreSax(isxml);
    }
}
```

Exemple de fichier XML

```
<?xml version='1.0' encoding="UTF-8"?>
<article lang="fr">
<section>
<para> <phrase>Deux nouveaux foyers de grippe aviaire ont été
détectés dans des élevages de canards de Dordogne et des
Landes, lundi 14 décembre.</phrase>
<phrase>Le ministère de l'agriculture recense à ce jour un
total de « 15 foyers d'influenza aviaire » dans cinq
départements du Sud-Ouest.</phrase> </para>
<para>
<phrase>Un cas de grippe de type H5N1 a été détecté et
confirmé lundi dans un élevage de 1 070 canards à Bosset
(Dordogne), près de Bergerac, indique le ministère sur son
site Internet.</phrase>
<phrase>C'est dans cette même commune qu'avait été détecté,
le 7 décembre, un premier foyer dans un élevage de 630
canards.</phrase> </para>
<para> <phrase>C'est aussi en Dordogne qu'avait été identifié
le tout premier cas de cette épizootie, le 24 novembre, dans
la basse-cour d'un particulier à Biras.</phrase> ...
```

Exécution et résultat

```
balise de fin: phrase
balise de début: phrase
Le ministère de l'agriculture recense à ce jour un total de «
15 foyers d'influenza aviaire » dans cinq départements du Sud-
Ouest.
balise de fin: phrase
balise de fin: para
balise de début: para
balise de début: phrase
Un cas de grippe de type H5N1 a été détecté et confirmé lundi
dans un élevage de 1 070 canards à Bosset (Dordogne), près de
Bergerac, indique le ministère sur son site Internet.
balise de fin: phrase
balise de début: phrase
C'est dans cette même commune qu'avait été détecté, le 7
décembre, un premier foyer dans un élevage de 630 canards.
balise de fin: phrase
balise de fin: para
balise de début: para
balise de début: phrase ...
```

Caractéristiques (1)

Nécessité d'une plate-forme de référence pour la gestion d'arborescence XML

Analyse et construction d'une arborescence de « nœuds » en mémoire,

Navigation, Modification, Sauvegarde partielle ou totale

Définition par l'Object Management Group (OMG)

1998 – Version 1.0

2000 – Version 2.0

2004 – Version 3.0 (www.w3.org/DOM/)

2015 – Version 4.0 (www.w3.org/TR/2015/REC-dom-20151119/)

Langages supportées

Pascal, C++ (Apache), Java, Perl (module), Python, Lingo (Director/Flash)

Caractéristiques (2) – Nœud

Élément constitutif de l'arborescence

Possibilité d'avoir des fils et un père

Typologie des nœuds

nœud document ou nœud racine (DOCUMENT_NODE)

nœud balise (ELEMENT_NODE)

nœud attribut (ATTRIBUTE_NODE)

nœud texte (TEXT_NODE)

nœud commentaire (COMMENT_NODE)

nœud entité (ENTITY_NODE)

Création à chaque nœud d'un ou plusieurs objets

Beaucoup de mémoire utilisée

Inadaptée pour les grands documents

Implémentation en Java

Librairie JAXP

+

Package org.w3c.dom (pas de support de Oracle)

interfaces (17) et une exception définissant le squelette des classes DOM.

Implémentation en Java (2) – Interface Node

Propriétés du nœud

String getNodeName() **String** getNamespaceURI()
short getNodeType() type du nœud
String getNodeValue() valeur du nœud
NamedNodeMap getAttributes() liste des nœuds attributs d'un nœud balise

Parcours dans l'arborescence des nœuds-balises

NodeList getChildNodes() liste des nœuds-fils
Node getFirstChild() premier des nœud-fils
Node getLastChild() dernier des nœud-fils
Node getNextSibling() prochain nœud-frère
Node getPreviousSibling() précédent nœud-frère
Node getParentNode() nœud père

Modification de l'arborescence

Node removeChild(**Node** oldChild) suppression d'un nœud
Node appendChild(**Node** newChild) ajout d'un nœud
Node replaceChild(**Node** newChild, **Node** oldChild) remplacement d'un nœud
void setNodeValue(**String** nodeValue) modification de la valeur d'un nœud

ParcoursArbreDom.java

Construction d'un objet DOM

```

public class GestionArbreDom {

    Document document = null;

    public GestionArbreDom(InputStream isXml) {
        // création d'une instance d'API DOM
        DocumentBuilderFactory factory =
            DocumentBuilderFactory.newInstance();

        // création d'un objet de construction
        DocumentBuilder builder = null;
        try {builder = factory.newDocumentBuilder();}
        catch (ParserConfigurationException e) {}

        // parcours et construction de l'arbre
        try {document = builder.parse(isXml);}
        catch (IOException e) {}
        catch (SAXException e){}
    }
  
```

ParcoursArbreDom.java

Parcours de l'arbre XML

```

/** Parcours complet de l'arbre */
public void ParcoursArbre() {
    if (document != null) ParcoursArbre(document);
}

/** Exploration récursive d'un nœud de l'arbre
 * @param node nœud */
private void ParcoursArbre(Node node){
    int type = node.getNodeType();
    switch (type){
        case Node.DOCUMENT_NODE:{
            System.out.println("début du document:");
            ParcoursArbre(((Document)node).getDocumentElement());
            System.out.println("fin du document:");
            break;
        }

        case Node.TEXT_NODE:{
            String st = node.getNodeValue().trim();
            if (st.length() > 0) System.out.println(st); break;
        }
    }
  
```


Lecture des balises, des attributs et des données

```

case Node.ELEMENT_NODE:{
System.out.print("balise de début: " + node.getNodeName());
// attributs
NamedNodeMap attrs = node.getAttributes();
for (int i = 0; i < attrs.getLength(); i++){
    Node attr = attrs.item(i);
    // nom
    System.out.print(" " + attr.getNodeName() + "=\\"");
    // valeur
    System.out.print(attr.getNodeValue()+"\");
} System.out.println();
NodeList children = node.getChildNodes();
if (children != null) {
    int len = children.getLength();
    for (int i = 0; i < len; i++)
        ParcoursArbre(children.item(i));
}
System.out.println("balise de fin: " + node.getNodeName());
break;
} }

```

Extractions à partir d'un fichier XML

```

import java.io.*;

/**
 * @author montacie
 */
public class testGestionArbreDom {

    public static void main(String[] args) {
        File fxml = new File("xml/article.xml");
        FileInputStream isxml = null;
        try {isxml = new FileInputStream(fxml);}
        catch (IOException e) {}

        GestionArbreDom ges = new GestionArbreDom(isxml);
        ges.ParcoursArbre();
    }
}

```